LAPORAN AKHIR PROJECT
ANALISIS BIG DATA



KELOMPOK 2

PENYUSUN:

1. Marsha Carolince (D121231013)
2. Nurul Arisah Hidayatullah (D121231118)
3. Azizah Awaliyah (D121231062)
4. Tasya Aulia Putri (D121221056)
5. Aurency Christabella Lolo (D121221074)
6. Anwar Bintang (D121221116)

TEKNIK INFORMATIKA

DEPARTEMEN TEKNIK INFORMATIKA

UNIVERSITAS HASANUDDIN

2025

Latar Belakang

Industri *e-commerce* beroperasi dalam lingkungan yang sangat kompetitif. Biaya untuk mengakuisisi pelanggan baru jauh lebih tinggi daripada biaya mempertahankan pelanggan yang sudah ada. Oleh karena itu, *customer churn*, atau tingkat perpindahan pelanggan ke kompetitor, menjadi salah satu metrik paling krusial yang menentukan profitabilitas dan keberlanjutan bisnis. Tingkat churn yang tinggi tidak hanya berarti kehilangan pendapatan langsung, tetapi juga mengindikasikan adanya masalah mendasar dalam produk, layanan, atau pengalaman pelanggan. Perusahaan e-commerce modern menghasilkan volume data yang sangat besar setiap detiknya. Data ini, jika diolah dengan benar, menyimpan wawasan berharga untuk memahami perilaku pelanggan secara mendalam.

Scenario Masalah

Perusahaan e-commerce Olist menghadapi masalah tingkat churn pelanggan yang tinggi. Banyak pelanggan baru hanya melakukan satu kali transaksi lalu tidak kembali melakukan pembelian.

Beberapa indikasi masalah yang terlihat dari data Olist:

1) Ada banyak single-purchase customers (pelanggan hanya belanja sekali lalu menghilang).
2) Pengiriman sering terlambat, terutama pada pelanggan yang lokasinya jauh dari seller.
3) Review pelanggan negatif meningkat ketika pengiriman tidak sesuai ekspektasi.
4) Metode pembayaran yang terbatas menyebabkan sebagian pelanggan meninggalkan transaksi (cart abandonment).

Akibatnya, Customer Lifetime Value (CLV) rendah dan biaya akuisisi pelanggan baru lebih tinggi daripada pendapatan jangka panjang.

Tujuan dan Sasaran Proyek

Proyek ini bertujuan untuk menganalisis dataset e-commerce Olist guna mengidentifikasi faktor-faktor utama penyebab *customer churn*. Dengan pendekatan analisis data yang efisien, tim akan melakukan pembersihan data, analisis eksplorasi, dan membangun satu model prediktif dasar. Outputnya adalah sebuah laporan analisis yang ringkas namun komprehensif. Adapun sasaran utama, yaitu untuk mengidentifikasi faktor yang paling berpengaruh terhadap *churn*, membangun satu model *Logistic Regression* sebagai bukti konsep, dan menyusun laporan yang merangkum metodologi, temuan, serta rekomendasi. Sumber yang digunakan dapat di akses melalui [https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce.]

Ruang Lingkup (Scope) dan Skala Proyek

- **Skala Objek:** Analisis berfokus pada jutaan data transaksi dari pelanggan retail perorangan dalam dataset Olist E-commerce.
- **Lingkup (In-Scope):**
    - Analisis pada file-file kunci dataset (customers, orders, reviews, payments).
    - Pembuatan fitur esensial seperti skor RFM dan rata-rata skor ulasan.
    - Pembangunan dan evaluasi satu model klasifikasi dasar.
- **Batasan (Out-of-Scope):**

- Analisis mendalam pada semua file dataset.
- Eksperimen dengan berbagai algoritma atau *hyperparameter tuning*.
- Implementasi model ke sistem produksi.

Metodologi Proyek

1. **Persiapan Data**

Data mentah dari beberapa file CSV (`customers`, `orders`, `order_reviews`, `order_payments`) digabungkan menjadi satu tabel data utama (*master table*) menggunakan `customer_id` dan `order_id` sebagai kunci. Proses pembersihan data mencakup penanganan nilai yang hilang (*missing values*) pada data ulasan dan konversi kolom tanggal ke format `datetime`.

2. **Definisi Operasional Churn**

Seorang pelanggan didefinisikan sebagai "churn" (bernilai 1) jika mereka hanya melakukan satu kali transaksi selama periode waktu dalam dataset. Sebaliknya, pelanggan yang melakukan lebih dari satu transaksi didefinisikan sebagai "loyal" (bernilai 0). Definisi ini dipilih untuk secara langsung mengatasi masalah inti yaitu *single-purchase customers*.

3. **Analisis Data Eksplorasi (EDA)**

EDA dilakukan untuk memahami karakteristik data dan menemukan pola awal terkait churn. Tim membuat beberapa visualisasi kunci untuk menjawab pertanyaan seperti:

- Bagaimana distribusi skor ulasan antara pelanggan loyal vs. churn?
- Apakah ada korelasi antara waktu pengiriman dengan skor ulasan?
- Bagaimana frekuensi penggunaan metode pembayaran yang berbeda?

4. **Rekayasa Fitur (*Feature Engineering*)**

Untuk memperkaya data sebelum pemodelan, beberapa fitur baru diciptakan, antara lain:

- Recency: Waktu (dalam hari) sejak pembelian terakhir.
- Frequency: Jumlah total pembelian.
- Monetary: Total nilai uang yang dibelanjakan.
- Avg_Review_Score: Rata-rata skor ulasan yang diberikan pelanggan.
- Delivery_Time: Waktu (dalam hari) yang dibutuhkan dari pesanan hingga diterima pelanggan.

5. **Pemodelan Prediktif**

Sesuai dengan tujuan, kami menggunakan algoritma Regresi Logistik (*Logistic Regression*). Algoritma ini dipilih karena kecepatannya, kesederhanaannya, dan yang terpenting,

kemampuannya untuk diinterpretasikan. Kemudahan interpretasi sangat krusial untuk mengidentifikasi faktor-faktor pendorong churn secara langsung.

Hasil Analisis

Berdasarkan hasil **analisis data eksplorasi (EDA)**:

1. **Distribusi Sentimen Review**
    - Mayoritas review pelanggan bersifat **positif (75%)**, sementara review **negatif (16.6%)** dan **netral (8.4%)** jauh lebih sedikit.
    - Hal ini menunjukkan bahwa sebagian besar pelanggan memiliki pengalaman belanja yang baik, namun review negatif meskipun jumlahnya kecil tetap berpotensi besar memicu churn.

2. **Frekuensi Pembelian per Bulan**
    - Terlihat tren kenaikan signifikan sejak akhir 2016 hingga puncaknya pada akhir 2017, di mana terjadi lonjakan transaksi lebih dari 9.000 pesanan.
    - Setelah itu, tren cenderung menurun meskipun masih stabil pada kisaran 7.000–8.000 pesanan per bulan di 2018.
    - Hal ini menandakan adanya faktor musiman (seasonality) dan kemungkinan ketergantungan pada periode promosi tertentu.

3. **Korelasi Variabel Transaksi**
    - Berdasarkan heatmap korelasi, faktor **harga (price)** memiliki korelasi tinggi dengan **payment_value (0.74)** dan **freight_value (0.42)**.
    - Namun, variabel-variabel utama seperti **review_score, payment_value, order_item_id** memiliki korelasi yang sangat rendah dengan churn, sehingga churn tidak dapat dijelaskan hanya dengan satu variabel tunggal.

4. **Korelasi Fitur dengan Churn**
    - Tidak ada variabel yang memiliki korelasi sangat tinggi dengan churn, namun terdapat indikasi bahwa **rata-rata sentimen review** (-0.07) dan **durasi hari** (-0.06) sedikit mempengaruhi kemungkinan churn.
    - Artinya, churn lebih banyak dipengaruhi oleh kombinasi variabel dibandingkan hanya satu variabel tunggal.

Hasil Model Regresi Logistik

1. **Faktor Penting dalam Prediksi Churn**
    - **Avg_Review_Score**: Faktor paling dominan. Pelanggan dengan skor ulasan rendah lebih cenderung churn.
    - **Delivery_Time**: Waktu pengiriman lebih lama meningkatkan kemungkinan churn.

- **Payment_Installments**: Pelanggan dengan cicilan pembayaran lebih banyak cenderung lebih loyal.

2. **Distribusi Prediksi Churn**
   - Hasil prediksi menunjukkan **39.600 pelanggan diprediksi No Churn** dan **27.800 pelanggan diprediksi Churn**.
   - Hal ini menunjukkan churn masih signifikan, sekitar **41% pelanggan berisiko churn**, sehingga intervensi bisnis perlu dilakukan.

3. **Evaluasi Model (Logistic Regression)**
   - **ROC Curve menghasilkan AUC = 0.549**, yang berarti model hanya sedikit lebih baik dibandingkan random guessing (AUC = 0.5).
   - Nilai ini menandakan bahwa model Logistic Regression dasar belum cukup kuat untuk prediksi churn, meskipun masih bisa memberikan insight mengenai faktor pendorong churn.

4. **Interpretasi Bisnis**
   - Meskipun performa model rendah, hasilnya sudah menunjukkan arah bahwa **pengalaman pelanggan (review dan delivery)** adalah faktor utama.
   - Dengan perbaikan data (misalnya feature engineering lebih lanjut, penanganan ketidakseimbangan kelas, atau mencoba algoritma lain seperti Random Forest, XGBoost), performa model bisa ditingkatkan.

Rekomendasi Bisnis

Berdasarkan temuan di atas, kami merekomendasikan tiga strategi utama untuk Olist:

1. Retensi Pelanggan Bernilai Tinggi

- Program Loyalitas VIP: Buat reward untuk pelanggan dengan transaksi besar/jangka lama (contoh: diskon eksklusif, early access produk baru, poin bonus).
- Personalized Retention Campaign: Kirim email/WhatsApp khusus ke pelanggan dengan skor churn tinggi berisi:
  - Promo personal (diskon di kategori yang sering dibeli).
  - Reminder benefit langganan.
  - Penawaran khusus jika mereka hampir tidak aktif.

2. Intervensi Customer Experience

- Analisis Sentimen Negatif: Dari kolom rata_sentimen, terlihat ada yang rendah → perlu ditindaklanjuti dengan:
  - Follow-up service call untuk memahami keluhan.

    - Survey kepuasan pelanggan secara berkala.

- Durasi Hari Aktif Rendah: Pelanggan dengan durasi pendek bisa diberikan welcome campaign yang lebih engaging (contoh: edukasi cara pakai produk, rekomendasi produk sesuai preferensi).

3. Optimasi Produk & Layanan

- Identifikasi Produk Churn-Driver: Lihat kategori produk yang sering dikaitkan dengan churn → tingkatkan kualitas atau lakukan perbaikan.
- Upselling & Cross-selling: Untuk pelanggan yang masih aktif tapi berisiko churn, tawarkan paket bundling atau diskon pembelian berikutnya agar mereka tetap engaged.

4. Strategi Jangka Panjang

- Segmen Pelanggan dengan Machine Learning Lanjutan: Karena AUC masih rendah, bisa ditingkatkan dengan model lain (Random Forest, XGBoost) atau feature engineering (misalnya frekuensi belanja per minggu, tren transaksi).
- Churn Prevention Dashboard: Buat dashboard monitoring real-time pelanggan berisiko churn agar tim marketing bisa langsung intervensi.
- Retention Team: Bentuk tim khusus yang fokus menurunkan churn, misalnya dengan target KPI “retensi pelanggan meningkat 10% per kuartal”.

Tim & Peran
Business user : Tasya Aulia Putri
Project sponsor : Tasya Aulia Putri
Project manager : Azizah Awaliyah
Business intelligence analyst : Aurency Christabella Lolo
Database administrator : Nurul Arisah Hidayatullah
Data engineer : Anwar Bintang
Data scientist : Marsha Carolince

Lampiran

- Kode Python untuk *cleaning* & *modelling*.

```python
import pandas as pd

df1 = pd.read_csv("/content/drive/MyDrive/tkbd/olist_orders_cleaned.csv")
df2 = pd.read_excel("/content/drive/MyDrive/tkbd/olist_order_review_cleaned.xlsx")
df3 = pd.read_csv("/content/drive/MyDrive/tkbd/olist_order_payments_cleaned.csv")
df4 = pd.read_csv("/content/drive/MyDrive/tkbd/olist_order_items_cleaned.csv")
df5 = pd.read_csv("/content/drive/MyDrive/tkbd/olist_customers_cleaned.csv")

gabungan = (
    df1
    .merge(df2, on="order_id", how="left")       # review ke orders
    .merge(df3, on="order_id", how="left")       # payments ke orders
    .merge(df4, on="order_id", how="left")       # items ke orders
    .merge(df5, on="customer_id", how="left")    # customer ke orders
)

print("Jumlah baris:", len(gabungan))
print("Jumlah kolom:", gabungan.shape[1])
print(gabungan.head())
```

```python
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, confusion_matrix

# ambil fitur & target
X = fitur[["total_transaksi", "jumlah_order", "rata_sentimen", "durasi_hari"]]
y = fitur["churn"]

# split data: 30% train, 70% test
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.7, random_state=42, stratify=y
)

# buat model Logistic Regression dengan balancing
logreg = LogisticRegression(max_iter=1000, class_weight="balanced", random_state=42)

# training
logreg.fit(X_train, y_train)

# prediksi di data testing
y_pred = logreg.predict(X_test)

# laporan evaluasi
print("=== Classification Report ===")
print(classification_report(y_test, y_pred, digits=3))

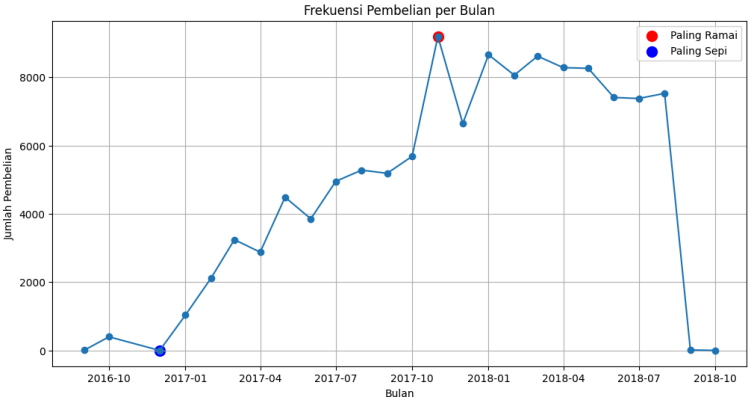
# confusion matrix
print("=== Confusion Matrix ===")
print(confusion_matrix(y_test, y_pred))
```

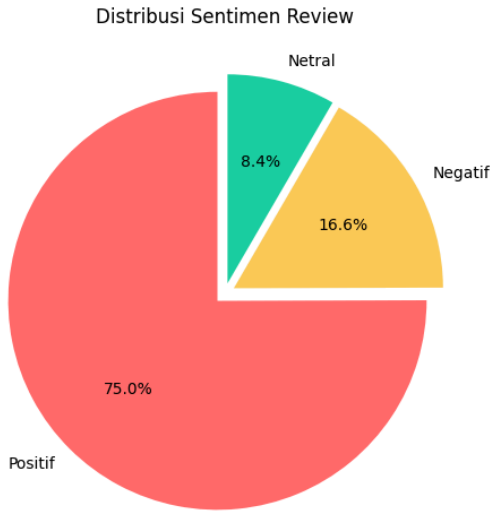
- Tabel hasil evaluasi model.

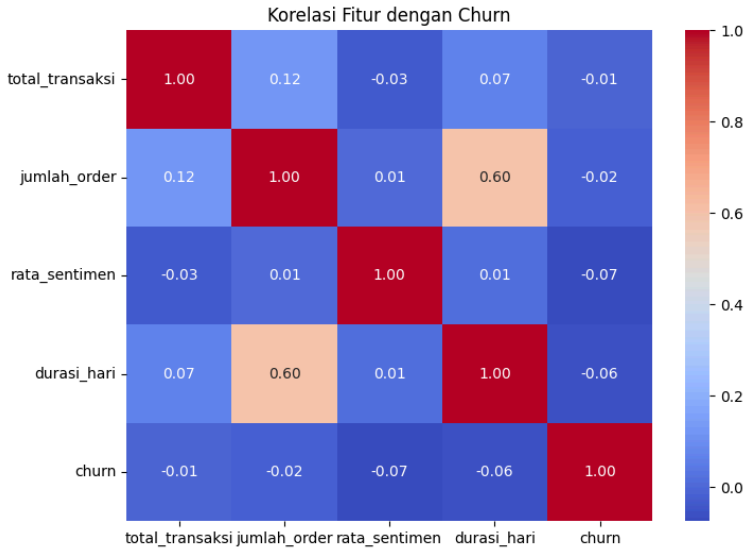
Metrik Evaluasi	Nilai	Interpretasi
Akurasi	0.59	Model memprediksi dengan benar sekitar 59% dari seluruh data
Precision	0.42	Dari semua pelanggan yang di prediksi churn, hanya 42% yang benar benar churn
Recall	0.47	Dari semua pelanggan yang benar benar churn, 47% berhasil terdeteksi model
F1-Score	0.44	Rata-rata harmonis antara precision dan recall untuk kelas churn
AUC (ROC)	0.549	Kemampuan model membedakan pelanggan churn dan non-churn sedikit di atas random (0.5).

- Grafik-grafik hasil EDA.




Frekuensi Pembelian per Bulan
Paling Ramai
Paling Sepi
Jumlah Pembelian
0
2000
4000
6000
8000
2016-10
2017-01
2017-04
2017-07
2017-10
2018-01
2018-04
2018-07
2018-10
Bulan


Distribusi Sentimen Review
Netral
8.4%
Negatif
16.6%
75.0%
Positif


Korelasi Fitur dengan Churn
total_transaksi
jumlah_order
rata_sentimen
durasi_hari
churn
1.00
0.12
-0.03
0.07
-0.01
0.12
1.00
0.01
0.60
-0.02
-0.03
0.01
1.00
0.01
-0.07
0.07
0.60
0.01
1.00
-0.06
-0.01
-0.02
-0.07
-0.06
1.00
total_transaksi
jumlah_order
rata_sentimen
durasi_hari
churn
1.0
0.8
0.6
0.4
0.2
0.0

- Notulen keputusan rapat tim.

Alokasi Tugas Harian :

1. Kamis, 18 Sep: Kick-Off, Persiapan & Setup Lingkungan Kerja.
2. Jumat, 19 Sep: Pembersihan & Penggabungan Data Utama.
3. Sabtu, 20 Sep: Analisis Data Eksplorasi (EDA) & Visualisasi
4. Minggu, 21 Sep: Rekayasa Fitur & Pemodelan Prediktif.
5. Senin, 22 Sep: Interpretasi Hasil & Penyusunan Draf Laporan.
6. Selasa, 23 Sep: Finalisasi Laporan & Review Tim.

Hak Akses Database :

1. Nurul Arisah Hidayatullah : Admin Penuh (Full Control)
2. Anwar Bintang : Baca & Tulis (Read & Write
3. Marsha Carolince : Hanya Baca (Read-Only)
4. Aurency Christabella Lolo : Hanya Baca (Read-Only)
5. Tasya Aulia Putri : Tidak Ada Akses Langsung
6. Azizah Awaliyah : Tidak Ada Akses Langsung